

抽样调查 第七周作业

20307100013 蒋翌坤

第四章 补充题:

题 1

(1) 引入示性函数 $Z_i = \begin{cases} 1, & \text{if } i \in S \\ 0, & \text{if } i \notin S \end{cases}$, 则 $E(Z_i) = \frac{n}{N}$, $E(Z_i^2) = \frac{n}{N}$, $E(Z_i Z_j) = \frac{n(n-1)}{N(N-1)}$

$$\begin{aligned} s_{yx} &= \frac{1}{n-1} \sum_{i \in S} (y_i x_i - x_i \bar{y} - y_i \bar{x} + \bar{y} \bar{x}) = \frac{1}{n-1} (\sum_{i \in S} (y_i x_i) - n \bar{x} \bar{y} - n \bar{x} \bar{y} + n \bar{y} \bar{x}) \\ &= \frac{1}{n-1} \left(\sum_{i \in S} (y_i x_i) - \frac{1}{n} (\sum_{i \in S} (y_i) \sum_{i \in S} (x_i)) \right) = \frac{1}{n-1} \left(\frac{n-1}{n} \sum_{i \in S} (y_i x_i) - \frac{1}{n} \sum_{i \neq j, i, j \in S} (y_i x_j) \right) \\ &= \frac{1}{n-1} \left(\frac{n-1}{n} \sum_{i=1}^N (y_i x_i Z_i^2) - \frac{1}{n} \sum_{i \neq j}^N (y_i x_j Z_i Z_j) \right) \\ E(s_{yx}) &= \frac{1}{n-1} \left(\frac{n-1}{N} \sum_{i=1}^N (y_i x_i) - \frac{(n-1)}{N(N-1)} \sum_{i \neq j}^N (y_i x_j) \right) \\ &= \frac{1}{n-1} \left(\frac{n-1}{N} \sum_{i=1}^N (y_i x_i) - \frac{(n-1)}{N(N-1)} (\sum_{i=1}^N (y_i) \sum_{i=1}^N (x_i) - \sum_{i=1}^N (y_i x_i)) \right) \\ &= \frac{1}{n-1} \left(\frac{(n-1)(N-1+1)}{N(N-1)} \sum_{i=1}^N (y_i x_i) - \frac{(n-1)}{N(N-1)} (N \bar{y}_u N \bar{x}_u) \right) \\ &= \frac{1}{N-1} (\sum_{i=1}^N (y_i x_i) - N (\bar{y}_u \times \bar{x}_u)) = \frac{1}{N-1} (\sum_{i=1}^N (y_i - \bar{y}_u) (x_i - \bar{x}_u)) = s_{yx} \end{aligned}$$

(2) 可知 $V(Z_i) = \frac{n}{N} \left(1 - \frac{n}{N} \right)$, 当 $i \neq j$ 时, $cov(Z_i, Z_j) = -\frac{1}{N-1} \left(1 - \frac{n}{N} \right) \left(\frac{n}{N} \right)$,

$$\begin{aligned} cov(\bar{y}, \bar{x}) &= \frac{1}{n^2} \sum_{i, j \in S} cov(y_i, x_j) = \frac{1}{n^2} \sum_{i, j=1}^N cov(Z_i y_i, Z_j x_j) = \frac{1}{n^2} \sum_{i, j=1}^N cov(Z_i y_i, Z_j x_j) \\ &= \frac{1}{n^2} \sum_{i, j=1}^N y_i x_j cov(Z_i, Z_j) = \frac{1}{n^2} \left(\sum_{i=1}^N y_i x_i \frac{n}{N} \left(1 - \frac{n}{N} \right) - \sum_{i \neq j}^N y_i x_j \frac{1}{N-1} \left(1 - \frac{n}{N} \right) \left(\frac{n}{N} \right) \right) \\ &= \frac{1-f}{n} \left(\frac{1}{N} \sum_{i=1}^N y_i x_i - \frac{1}{N(N-1)} \sum_{i \neq j}^N y_i x_j \right) = \frac{1-f}{n} s_{yx} \end{aligned}$$

题 2

(1) $E(\bar{y}_s) = \frac{\binom{N-2}{n-1}}{\binom{N-1}{n}} E(\bar{y} + c) + \frac{\binom{N-2}{n-1}}{\binom{N-1}{n}} E(\bar{y} - c) + \left(1 - \frac{2\binom{N-2}{n-1}}{\binom{N-1}{n}} \right) E(\bar{y}) = E(\bar{y}) = \bar{y}_u$

所以 \bar{y}_s 是 \bar{y}_u 的无偏估计

(2) 引入与题 1 相同的示性函数 $Z_i = \begin{cases} 1, & \text{if } i \in S \\ 0, & \text{if } i \notin S \end{cases}$

不失一般性, 令 $y_1 = y_{(1)}, y_N = y_{(N)}$

$$\begin{aligned} V(\bar{y}_s) &= V \left(\frac{1}{n} (\sum_{i=1}^N Z_i y_i) + c(Z_1 - Z_N) \right) = \frac{1}{n^2} V \left(\sum_{i=1}^N Z_i y_i + nc(Z_1 - Z_N) \right) \\ &= \frac{1}{n^2} Cov \left(\sum_{i=1}^N Z_i y_i + nc(Z_1 - Z_N), \sum_{j=1}^N Z_j y_j + nc(Z_1 - Z_N) \right) \end{aligned}$$

$$\begin{aligned}
&= \frac{1}{n^2} \sum_{i,j=1}^N y_i y_j \text{Cov}(Z_i, Z_j) + y_i n c (\text{Cov}(Z_i, Z_1) - \text{Cov}(Z_i, Z_N)) + y_j n c (\text{Cov}(Z_j, Z_1) - \\
&\text{Cov}(Z_j, Z_N)) + n^2 c^2 (V(Z_1) + V(Z_N) - 2\text{Cov}(Z_1, Z_N)) \\
&= \frac{1}{n^2} \left(\sum_{i=1}^N y_i^2 V(Z_i) + \sum_{i \neq j}^N y_i y_j \text{Cov}(Z_i, Z_j) + 2(y_1 - y_N) n c \left(\frac{n}{N} \left(1 - \frac{n}{N} \right) + \frac{1}{N-1} \left(1 - \frac{n}{N} \right) \left(\frac{n}{N} \right) \right) + \right. \\
&\left. 2n^2 c^2 \frac{N}{N-1} \left(\frac{n}{N} \left(1 - \frac{n}{N} \right) \right) \right) \\
&= (1-f) \frac{S^2}{n} + (1-f) \frac{2c}{N-1} (y_1 - y_N) + (1-f) 2c^2 \frac{N}{N-1} \frac{n}{N} \\
&= (1-f) \left(\frac{S^2}{n} - \frac{2c}{N-1} (y_{(N)} - y_{(1)} - nc) \right)
\end{aligned}$$

(3) 当 $V(\bar{y}_s) < V(\bar{y})$, 即 $\frac{2c}{N-1} (y_{(N)} - y_{(1)} - nc) > 0$, 即 $0 < c < \frac{y_{(N)} - y_{(1)}}{n}$ 时, \bar{y}_s 优于 \bar{y}

当 $\frac{2c}{N-1} (y_{(N)} - y_{(1)} - nc)$ 取最大, 即 $c = \frac{y_{(N)} - y_{(1)}}{2n}$ 时, \bar{y}_s 最优

题 3


(1) 计算可得 $\hat{B} = 0.987$, $SE(\hat{B}) = 5.75 \times 10^{-3}$, 95%置信区间为 [0.975, 0.998]

(2) 每次 bootstrap 从 300 个 SRS 样本中有放回的抽取 100 个样本, 进行 1000 次, 得到 1000 个 \hat{B} 。从这 1000 个 \hat{B} 中, 可以得到 95%置信区间为 [0.967, 1.007]

§ 4.8 Exercises:

题 3


(a) x 和 y 的散点图如下所示:



(b) 计算可得: $\bar{y}_r = 117.62$, $SE(\bar{y}_r) = 3.91$

(c) 计算可得: $\bar{y} = 107.4$, $SE(\bar{y}) = 6.19$

(d) 标出所得到的估计如下图所示：



由于样本中相关系数 $r = 0.78 > 0.5$ ，所以用比估计更合适。

题 4

(a) Domain 2 中有孩子的家庭比例为0.486，95%置信区间为[0.456,0.517]

(b) Domain 2 中家庭平均孩子数为0.884，95%置信区间为[0.8200.949]

(c) Domain 2 中家庭总孩子数为242400, 95%置信区间为[224691,260109]

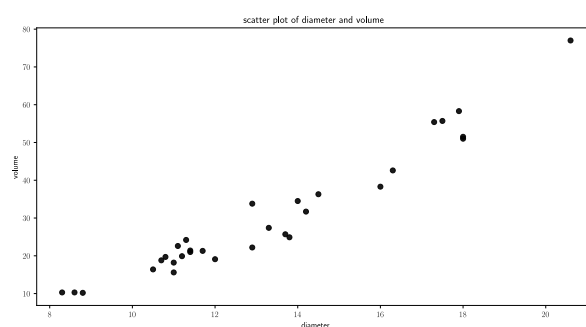
题 9

(a) 在拘捕中，burglary 占比为0.059，95%置信区间为[0.052,0.066]

(b) 家庭内的严重攻击行为数为76120, 95%置信区间为[55927,96312]

题 11

(a) volume 和 diameter 的散点图如下图所示：




(b) 利用比估计，所有树的总体积为95272, 95%置信区间为[84548,105996]

(d) 利用简单估计，所有树的体积为89517, 95%置信区间为[72438,106596]。由于样本中相关系数 $r = 0.97 > 0.5$ ，所以用比估计更合适。

题 13

(a) physicians 的直方图如下图所示：



(b) 利用简单估计，全美内科医生总数为 933411，标准误为 491983

(c) 利用比估计，全美内科医生总数为 639506，标准误为 87885.3

(e) 比估计更接近总体中内科医生的真实人数。这是由于内科医生与县人口的相关系数高达 0.98，如果用简单估计，由于县人口差距很大，导致得出的样本均值不能很好的反应各个县的平均内科医生数量，而用比估计可以很好的避免这个问题。

附录：

解答题目所使用的代码及输出请见：

<https://thisiskunmeng.github.io/sampling/hw7.html>